
시간·계절·날씨에 따른

서울시 전체 따릉이 수요 예측



CONTENTS

목차

-
- 01 프로젝트 선정 배경
 - 02 분석 과정 요약
 - 03 데이터 EDA
 - 04 데이터 전처리 / 피처 엔지니어링
 - 05 Train/Test set 분할
 - 06 모델링
 - 07 예측
-

프로젝트 선정 배경

01

실무적 의사결정과 관련된 예측

수요 예측은 자전거 재배치 등 실무적 의사결정과 직결

02

시간·계절·날씨에 따른 도시 전체의 수요 변화

데이터 구조상 도시 전체의 수요 변화 분석에 적합

03

여러 방법론을 함께 적용해볼 수 있는 데이터

이론적으로 배운 내용을 적용하기에 적합

분석 과정 요약

원본 데이터 컬럼

Date	Rented Bike Count	Hour	Temperature	Humidity	Wind speed	Visibility	Dew point temperature	Solar Radiation
Rainfall	Snowfall	Seasons	Holiday	Functioning Day				

STEP 1
데이터 확인

STEP 2
EDA
전체, 범주형, 시간, 기상

STEP 3
전처리 / 피처 엔지니어링

STEP 4
Train/Test set 분할

STEP 5
모델링
베이스라인, 후보 모델

STEP 6
예측

전체 데이터 EDA

8,760

개의 행

없음

결측값

없음

중복값

4개

문자형 데이터

4개

정수형

6개

실수형

Data columns (total 14 columns):

#	Column	Non-Null Count	Dtype
0	Date	8760 non-null	str
1	Rented_Bike_Count	8760 non-null	int64
2	Hour	8760 non-null	int64
3	Temperature	8760 non-null	float64
4	Humidity	8760 non-null	int64
5	Wind_speed	8760 non-null	float64
6	Visibility	8760 non-null	int64
7	Dew_point_temperature	8760 non-null	float64
8	Solar_Radiation	8760 non-null	float64
9	Rainfall	8760 non-null	float64
10	Snowfall	8760 non-null	float64
11	Seasons	8760 non-null	str
12	Holiday	8760 non-null	str
13	Functioning_Day	8760 non-null	str

dtypes: float64(6), int64(4), str(4)
memory usage: 1.2 MB

이상치 확인

이상치 개수

158개

$\text{lower_bound} = Q1 - 1.5 * IQR$
 $\text{upper_bound} = Q3 + 1.5 * IQR$

1 변수값 확인



2 특정 시간대, 특정 계절에 몰려있음 확인

3 정상적인 피크 수요로 결론


→ 제거 X

종속 변수 분포

Skewness = 1.139 → 제곱근변환 필요




Time



시간대별 평균 대여량

8시, 18시 수요가 뚜렷한 피크를 보이는 이중봉 형태



계절별 시간대 대여량


낮 시간대에는 계절 간 차이가 크지 않지만 저녁(19~22시) 시간대에서 여름의 대여량이 다른 계절보다 뚜렷하게 높아진다. 이는 3번 파트에서 확인한 '여름철 저녁 이용 집중' 현상과 일치한다

기상 변수별 분포


비운영날은 제거

Skewness가 큼

Wind_speed




Visibility




Visibility는 상한값(2000)에 관측값 집중

비교적 대칭


Temperature



Humidity




Dew_point_temperature




0 비율이 매우 높음


Solar_Radiation



Rainfall




Snowfall



0을 제외한 값(non-zero)만 그린 분포

기상변수와 대여량의 상관관계 (Pearson과 Spearman)





Solar_Radiation · Rainfall · Snowfall

대부분의 값이 0이라는 zero-inflation 구조 때문에 Pearson-Spearman 차이 발생 → 고려할 필요 X

나머지 연속형 변수

Temperature, Humidity, Wind_speed, Visibility,
Dew_point_temperature는 abs_diff가 모두 0.05 이하로 작아 뚜렷한 비선형 패턴 증거 없음

기상변수와 대여량의 상관관계 (산점도, 박스플롯)



Humidity · Wind_speed

실제 산점도를 그려보니 역U자형(비선형) 관계

Temperature

S자선, 일정 구간까지만 선형적 증가 그 이후에는 증가폭 둔화

Visibility

관계 자체보다는 계기 상한으로 인한 데이터 구조가 추세선 모양에 영향을 준 것으로 해석

Dew_point_temperature

Temperature와 유사 (Temperature와의 상관계수가 0.91로 사실상 같은 정보) → 다중공선성의 시각적 증거

Solar_Radiation

전형적인 zero-inflated 변수의 산점도. 이산적 구분이 추세의 대부분을 설명하며 연속값으로서의 선형 관계는 상대적으로 약함

Rainfall / Snowfall

양보다 유무

이상치

비교 기준

IQR 기준 이상치 개수/비율을 변수별로 비교

처리 방침


Humidity=0과 Visibility=2000처럼 '값이 이상해서'가 아니라 '계기의 측정 한계'로 생기는 값들은 제거 대상이 아니라 별도로 기록

Humidity = 0 인 행 수: 17

	Date	Hour	Humidity	Temperature	Seasons
4063	2018-05-19	7	0	11.4	Spring
4106	2018-05-21	2	0	13.9	Spring
4107	2018-05-21	3	0	13.0	Spring
4108	2018-05-21	4	0	12.4	Spring
4109	2018-05-21	5	0	11.9	Spring

Visibility = 2000(상한) 인 행 수: 2150 / 전체 8465 (25.4%)

다중공선성 확인



Dew_point_temperature는 Temperature, Humidity와 물리적으로 강하게 연동되는 변수라 VIF가 높게 나올 가능성이 큼 → 모델링 중 다중선형회귀 모형에서 제거 필요

variable	VIF
Dew_point_temperature	116.219367
Temperature	87.152504
Humidity	20.132908
Solar_Radiation	1.975087
Visibility	1.565867
Wind_speed	1.198871
Snowfall	1.093974
Rainfall	1.080975

범주형 변수 (Functioning_Day)

Seasons

거의 균등

계절별 각 약 25%

Holiday

5%

공휴일 432개

Functioning_Day

3%

No 295개

→ 비운영날 제거

범주형 변수 (Seasons)

비모수 검정인 Kruskal-Wallis 검정 사용

Kruskal-Wallis $H = 2513.76$, $p\text{-value} = 0.000e+00$
효과크기 $\epsilon^2 = 0.297$

→ 계절 간 분포에 유의한 차이

→ 효과크기 $\epsilon^2 = 0.297$ · 큰 효과 (0.26 이상이면 큼)

계절별 평균 대여량

여름
1,034

가을
924

봄
746

겨울
226

어떤 계절끼리 다른지 보기 위해 계절 두 개씩 Mann-Whitney 검정

여러 번 검정한 만큼 Bonferroni 보정($p\text{값} \times 6$) 적용

→ 6개 계절 쌍 모두 보정 $p < 0.05$ 로 유의

비교 (A - B)	평균 차이	중앙값 차이	보정 p값
봄 - 여름	-287.8	-306.5	< 0.0001
봄 - 가을	-177.9	-257.0	< 0.0001
봄 - 겨울	520.7	396.0	< 0.0001
여름 - 가을	110.0	49.5	0.0001
여름 - 겨울	808.5	702.5	< 0.0001
가을 - 겨울	698.6	653.0	< 0.0001

→ 여름-가을 차이가 가장 작고, 겨울과 나머지 계절의 차이가 가장 큼

범주형 변수 (Seasons · 시간대)

왜 여름이 많을까?

가설) 여름에는 해가 길어서 저녁까지 탈 수 있기에 많은 것 같다

→ 계절별 시간대 그래프로 저녁시간에 차이가 나는지 확인

→ 저녁, 밤 시간대의 이유 O

저녁(19~22시) 대여 비중


여름
28.3%

봄
23.6%

가을
23.6%

겨울
18.7%

저녁(19~22시)에는 여름이 봄·가을 평균보다 약 570건 많음




시간대	봄	여름	가을	겨울	여름 - 봄·가을 평균
새벽(0~6시)	250	486	370	102	176
출근(7~9시)	774	1077	994	295	193
낮(10~16시)	856	908	995	264	-18
퇴근(17~18시)	1499	1831	1773	390	195
저녁(19~22시)	1057	1753	1305	253	572
밤(23시)	623	1154	829	173	428

03 · 데이터 EDA

범주형 변수 (요일)

공휴일, 주말, 주중(공휴일X) 여부별 대여량



DayType별 표본 수와 대여량

DayType	hours	days	mean	median
Workday	5712	238	756.2	580.0
Weekend	2345	98	698.1	509.0
Holiday	408	17	529.2	259.0

출퇴근 피크는 근무일에만 있고 주말, 공휴일은 오후에 여가로 타는 패턴

범주형 변수 (Holiday)

1 · 계절

겨울에 공휴일이 모여있음

→ 같은 계절 안에서의 공휴일 비공휴일 비교

→ 차이가 줄음

2 · 관측 단위

같은 날의 24시간은 계절이 같고 날씨가 크게 다르지 않음

→ 하루를 하나의 관측값 (p-value가 실제보다 훨씬 작게 나오는 것을 방지)

→ 그냥 비교, 계절 맞춤, 기온 구간 맞춤, 기온과 비 회귀

비교 방법	공휴일이 적은 정도 (시간당)
그냥 비교 (3-4)	210건
계절 맞춤 (3-6)	51건
기온 구간 맞춤 (방법 1)	95건
기온·비 회귀 (방법 2)	149건 ($p \approx 0.006$)

→ 공휴일에 덜 타는 것은 맞다

데이터 전처리 / 피처 엔지니어링

전체 데이터

- Functioning_Day = No인 295개 행 제거
- 종속변수(Rented_bike_count) → 원변수 유지, 제곱근 변환한 종속변수 (rented_bike_count_sqrt) 생성

범주형 변수

- Holiday 더미 변수화, Seasons 변수 원-핫 인코딩
- (주말, 공휴일)과 (평일)을 이진으로 구분하는 Is_dayoff 변수 생성 (주말, 공휴일 = 1, 평일 = 0)

시간 변수

- 파생변수 - Date에서 월(Month), 요일(Weekday), 주말 여부 (Is_Weekend: 이진변수) 추출하여 추가
- Hour 원-핫 인코딩 → 더미 변수로 (Hour_0~Hour_23)
- 시간을 새벽(0~5시), 출근(6~9시), 낮(10~16시), 퇴근(17~20시), 밤(21~23시) 이렇게 구간별로 나눈 hour_band 변수 추가


기상 변수

- Rainfall/Snowfall → Rain_YN, Snow_YN 이진변수 (0/1 정수, 원본 유지)
- Humidity, Wind_speed 평균 중심화 후 제곱 → Humidity_sq, Wind_speed_sq

* 회귀용 데이터셋에는 Month 더미 또는 Seasons 더미 중 하나만 사용 (두 개 겹침)

train: 6,497행 (76.8%)
test : 1,968행 (23.2%)

- 랜덤 분할X → 매달 마지막 7일을 test로 지정
- 분할 → assert 통해 겹침 검증 → train 6497행(76.8%) / test 1968행(23.2%)
- 9월은 운영 중단일(Functioning_Day=No)이 있어 test가 5일
- 기상 제공항을 train 평균으로 다시 중심화 (humidity, wind_speed)



베이스라인: 다중선형회귀 변수 구성

EDA에서 확인한 비선형성·시간대 효과를 반영하되, 기준이 되는 선형모형부터 비교

Target

Rented_Bike_Count_sqrt

대여량의 왜도를 완화하기 위해 제곱근 변환한 종속변수 사용

주요 입력 변수

- 기상 연속형 7개 (Dew_point 제외) + 제곱항 2개
- Rain_YN · Snow_YN
- Hour 더미 23개 (Hour_0 기준)
- Seasons 더미 3개 (Autumn 기준)
- Is_dayoff

Humidity² · Wind_speed²로 EDA에서 확인한 역U자 관계 반영

제외·누수 방지

- Dew_point_temperature: 다중공선성 우려
- 중복·인코딩 완료 변수 제외
- Functioning_Day: 상수열
- StandardScaler는 Train에만 fit

Test 정보가 학습 과정에 들어가지 않도록 전처리 기준을 Train에서만 산출

베이스라인 회귀 결과

선형회귀를 기준으로 설정하고, 이후 트리 기반 모델의 개선 폭을 비교

Test RMSE

315.08

시간당 평균 대여량(약 730대)의
43% 수준

Test MAE

213.49

평균 절대 오차

Test R^2

0.7384

설명력

Train R^2

0.7334

Gap -0.005 — 뚜렷한 과적합은
확인되지 않음

결과 해석

- 기본적인 시간·기상 효과는 설명 가능
- 하지만 비선형성과 복잡한 시간대 패턴을 충분히 표현하기에는 한계
- 다음 단계에서 비선형·상호작용을 학습하는 트리 모델로 확장
- 절대오차 상위 10건 중 7건이 18~19시 퇴근 피크에 집중

예측 오차가 큰 구간

피크 시간대와 급격한 날씨 변화 구간에서 오차가 상대적으로 커지는 양상

→ 선형모형의 한계를 다음 진단에서 확인

회귀모형 진단: 선형모형의 한계

잔차·정규성·자기상관·다중공선성을 확인하여 다음 모델 선택의 근거로 활용 (Train 기준 · 제공근 변환 단위 잔차)

잔차 플롯

적합값이 커질수록 잔차가 퍼지는 패턴

- 등분산 가정이 약함
- 피크 수요에서 오차가 커질 가능성

Q-Q Plot

양 끝단에서 정규성 이탈

- 극단적인 수요 구간을 선형모형이 완전히 설명하기 어려움

자기상관 · 다중공선성

Durbin-Watson

0.446

강한 양의 자기상관

VIF 최대

5.64

심각한 다중공선성은
아님

시계열 구조는 잔차에 남아 있으며, 변수 간 중복 문제는 비교적 통제됨

결론 → 선형모형을 기준선으로 유지하고, 비선형 관계와 변수 상호작용을 학습할 RF·XGBoost로 확장

후보 모델 설정 및 학습 전 점검

후보 모델

Random Forest

여러 결정트리를 앙상블하여 비선형 관계를 학습

XGBoost

이전 모델의 오차를 보완하는 방식으로 순차적으로 트리를 학습



공통 조건: 기본 하이퍼파라미터 · random_state=42

입력 데이터 점검

- 결측치 0건 / 무한대 0건
- Target leakage 여부 확인
- 상수열 점검 → 해당 없음, 최종 feature 44개
- Train / Test에서 X, y 분리
- 동일한 평가 함수로 RMSE · MAE · R^2 비교
- Dew_point_temperature · Seasons 4개 모두 유지 (트리는 다중공선성 · 더미 트랩 영향 적음)
- Train ($6,497 \times 44$) / Test ($1,968 \times 44$)

Test set은 학습 · 튜닝에 사용하지 않고 최종 성능 평가에 사용

후보 모델 성능 비교




XGBoost: Test RMSE 185.73 / MAE 125.50 / R^2 0.9091


RF Train R^2 0.9880 / Gap 0.0986 · XGB Train R^2 0.9874 / Gap 0.0783 — 두 모델 모두 기본 파라미터 기준 과적합 경향이 있으나 XGBoost가 Gap도 더 작음

변수 중요도: 모델이 활용한 핵심 정보

Random Forest · Feature Importance Top 5



XGBoost · Feature Importance Top 5



RF는 기상 변수, XGBoost는 시간대 변수가 상대적으로 높은 중요도를 보임

- 특히 17~19시 변수의 중요도가 높아 EDA에서 확인한 출퇴근 피크와 일관된 결과
- XGBoost는 새벽(Hour_3~5)에도 큰 가중치 — 저수요 구간을 잘라내는 분기 역할
- 주의: RF는 불순도 감소, XGBoost는 gain 기준이라 수치 직접 비교는 불가 (경향만 해석)

EDA 결과와 모델의 연결

앞 파트의 EDA 결론이 어떤 변수로 설계되어, 모델 중요도에서 다시 확인되었는가

EDA에서 찾은 패턴	설계한 변수	모델에서의 활용
출퇴근 이중봉 (8시 · 18시)	Hour 더미 24개	XGBoost 중요도 1~3위 (Hour_18 · 19 · 17)
여름철 저녁 이용 집중	Seasons 더미	Seasons 변수가 XGBoost 상위권 (Autumn 8위)
주말 · 공휴일 패턴이 유사	Is_dayoff로 통합	RF 중요도 5위 (0.038)
비 · 눈은 양보다 유무	Rain_YN · Snow_YN	회귀 · 트리 모두 투입
습도 · 풍속의 역U자 관계	Humidity_sq · Wind_speed_sq	회귀의 비선형 보정 역할
Temperature-Dew_point $r = 0.91$	회귀 제외 / 트리 유지	RF 중요도 12위 (0.020)

→ EDA에서 찾은 패턴이 변수 설계로 이어지고, 그 변수들이 모델에서 실제로 활용됨

Test 구간 예측 결과

매월 마지막 7일로 구성된 Test 1,968행에서 실제 대여량과 RF·XGBoost 예측을 비교

Test observations

1,968

전체의 23.2%

RF 음수 예측

0건

음수 예측 없음

XGBoost 음수 예측

27건

새벽 저수요 구간에서 발생

오차가 커지는 구간

- 수요가 급증하는 피크 시간대
- 강수 또는 급격한 기온 변화 시점
- 저수요 구간에서는 XGBoost의 음수 예측도 일부 발생
- 결과 저장: RF_XGB_model_results.csv, Feature Importance, 예측값 CSV

후처리 시 유의점

대여량은 음수가 될 수 없으므로 실제 적용에서는 음수 예측을 0으로 클리핑하는 후처리 필요

※ 클리핑 전 185.73 / 125.50 / 0.9091

→ 클리핑 후 185.45 / 125.05 / 0.9094 (변화 미미)

전체 모델 종합 비교

모델	Test RMSE	Test MAE	Test R ²	Baseline 대비 RMSE
Linear Regression	315.08	213.49	0.7384	—
Random Forest	204.79	133.18	0.8895	35.00% 개선
XGBoost	185.73	125.50	0.9091	41.05% 개선

비교 결과

- 선형회귀보다 RF·XGBoost의 Test 성능이 크게 개선
- XGBoost는 이번 비교에서 Test RMSE·MAE가 가장 낮고 R²가 가장 높음
- 기본 하이퍼파라미터 기준 결과이므로 최적 모델이라고 단정하기보다 후속 튜닝이 필요

CONCLUSION

결론

EDA에서 모델 비교까지 — 무엇을 확인했는가

핵심 결과

- 1 시간대와 기상 조건(기온 · 습도 · 일조량)이 수요를 설명하는 주요 요인 — 두 요인의 상대적 비중은 모델에 따라 다르게 나타남
- 2 EDA에서 확인한 시간대 · 계절 · 기상 패턴이 변수 설계와 모델의 변수 중요도에 반영됨
- 3 선형회귀는 Test R^2 0.7384로 기준선 역할 — 비선형성과 복잡한 시간대 패턴을 충분히 표현하기 어려움
- 4 트리 기반 모델로 확장한 결과 Test RMSE 315.08 → 185.73 (41.05% 개선), XGBoost Test R^2 0.9091
- 5 기본 하이퍼파라미터 기준 비교이므로 최적 모델로 단정하기보다 후속 튜닝이 필요

→ 비선형 관계와 시간대 패턴을 학습하는 트리 기반 모델의 개선 효과를 확인